


Experiência 02: laboratório de Classificação Visual

Análise de Viés em IA – Teachable Machine

Evidência Visual de Falha



Durante o treinamento no Teachable Machine (<https://teachablemachine.withgoogle.com/models/3u1y-FSgb/>), a escolha limitada de exemplos para “introvertido” e “extrovertido” reduz a diversidade comportamental representada. O modelo aprende padrões superficiais, como expressão facial, postura ou posição diante da câmera, e associa esses sinais a categorias complexas de personalidade. Como os dados não representam a real variedade do comportamento humano, o algoritmo simplifica a interpretação e gera classificações baseadas em estereótipos. No exemplo apresentado, o sistema atribui um resultado que não corresponde à percepção do próprio indivíduo, evidenciando a distorção causada pelo viés.

Mecanismo do Viés

Durante o treinamento no Teachable Machine, a escolha limitada de exemplos para “introvertido” e “extrovertido” reduz a diversidade comportamental representada. O modelo aprende padrões superficiais, como expressões faciais ou posturas específicas, e associa esses sinais a categorias complexas. Como os dados não abrangem variações reais de personalidade, o algoritmo simplifica o problema e produz classificações baseadas em estereótipos.

Consequência Social

Ao classificar pessoas com base em padrões limitados, o sistema rotula indivíduos de forma imprecisa. Em contextos sociais ou profissionais, essa classificação influencia percepções externas e pode limitar oportunidades, especialmente se características como timidez ou expressividade forem mal interpretadas. Assim, o uso desse tipo de modelo reforça julgamentos simplistas e contribui para a exclusão ou invisibilização de perfis que não se encaixam nos padrões treinados.

Ação Mitigadora

A revisão humana na seleção e validação dos dados. Avaliadores analisam se os exemplos representam diferentes formas de introversão e extroversão, evitando associações estereotipadas. Durante o uso do modelo, humanos monitoram as classificações e corrigem erros recorrentes. Esse processo garante maior equilíbrio na base de dados e reduz interpretações simplificadas, tornando o sistema mais justo.